Análise Sintática

Guido Araújo guido@ic.unicamp.br







Introdução

Análise Léxica:

- Quebra a entrada em palavras conhecidas como tokens
- Análise Sintática:
 - Analisa a estrutura de frases do programa
- Análise Semântica:
 - Calcula o "significado" do programa





Analisador Sintático (Parser)

- Receba uma seqüência de tokens do analisador léxico e determine se a string pode ser gerada através da gramática da linguagem fonte.
- É esperado ainda que ele reporte os erros de uma maneira inteligível
- Seja capaz de se recuperar de erros comuns, continuando a processar a entrada

MC910: Construção de Compiladores http://www.ic.unicamp.br/~guido





Analisador Sintático (Parser)

- Seja capaz para expressar a sintaxe de linguagens de programação
 - Que tal dar nomes à ERs?

$$expr = ab(c|d)e$$



 $aux = c \mid d$ expr = a b aux e





Exemplo de ER usando nomes:

- digits = [0-9]+
- sum = (digits "+")* digits

Como isso é implementado?

- O analisador léxico substitui os nomes das ERs antes de traduzir para um autômato finito
- sum = ([0-9] + "+") * [0-9] +



 É possível usar a mesma idéia para definir uma linguagem para expressões que tenham parênteses balanceados?

$$(1+(245+2))$$

- Tentativa:
 - digits = [0-9]+
 - sum = expr "+" expr
 - expr = "(" sum ")" | digits







- digits = [0-9]+
- sum = expr "+" expr
- expr = "(" sum ")" | digits
- O analisador léxico substituiria sum em expr:
 - expr = "(" expr "+" expr ")" | digits
- Depois substituiria expr no próprio expr:
 - expr = "(" "(" expr "+" expr ")" | digits "+" expr ")" |
 digits

O que está ocorrendo aqui?



- ERs são boas para definir a estrutura léxica de maneira declarativa
- Não são "poderosas" o suficiente para conseguir definir declarativamente a estrutura sintática de linguagens de programação
- Que notação usar para representar
 "palavras" (cadeias) dentro de uma frase?

Gramáticas Livre de Contexto

- Nomes não acrescentam a ERs o poder de expressar recursão.
- É isso que precisamos para expressar a recursão mútua entre sum e expr
- O que está faltando então?





Gramáticas Livre de Contexto

 Descreve uma linguagem através de um conjunto de produções da forma:

symbol -> symbol symbol ... symbol

Símbolos:

- terminais: uma string do alfabeto da linguagem
- não-terminais: aparecem do lado esquerdo
- nenhum token aparece do lado esquerdo
- existe um n\u00e3o-terminal definido como start symbol



Gramáticas Livre de Contexto

$$1.S \rightarrow S$$
; S
 $2.S \rightarrow id = E$
 $3.S \rightarrow print (L)$
 $4.E \rightarrow id$
 $5.E \rightarrow num$

$$6.E \rightarrow E + E$$

 $7.E \rightarrow (S, E)$
 $8.L \rightarrow E$
 $9.L \rightarrow L, E$

Possível código fonte:

$$a := 7;$$

$$b := c + (d := 5 + 6, d)$$







Derivações

$$a := 7; b := c + (d := 5 + 6, d)$$

- <u>S</u>
- S; <u>S</u>
- <u>S</u>; id := E
- id := E; id := E
- id := num ; id := <u>E</u>
- id := num ; id := *E* + *E*
- id := num ; id := <u>E</u> + (S, E)
- id := num ; id := id + (<u>S</u>, <u>E</u>)
- id := num ; id := id + (id := <u>E</u>, <u>E</u>)
- id := num ; id := id + (id := *E* + *E*, *E*)
- id := num ; id := id + (id := <u>E</u> + <u>E</u>, id)
- id := num ; id := id + (id := num + <u>E</u>, id)
- id := num ; id := id + (id := num + num, id)



Derivações

- left-most: o não terminal mais a esquerda é sempre o expandido;
- right-most: idem para o mais a direita.
- Qual é o caso do exemplo anterior?



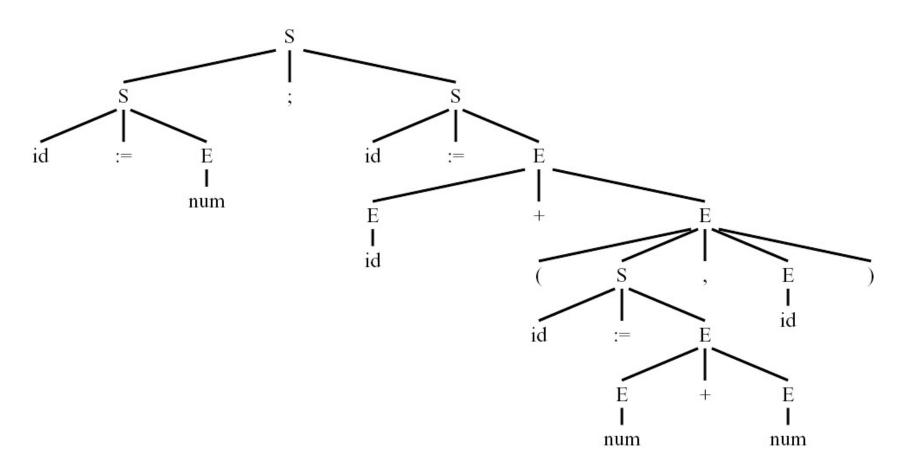
Parse Trees

- Constrói-se uma árvore conectando-se cada símbolo em uma derivação da qual ele foi derivado
- Duas derivações diferentes podem levar a uma mesma parse tree



Parse Trees

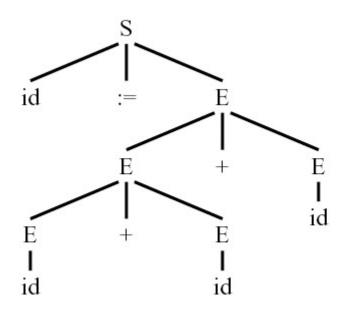
$$a := 7; b := c + (d := 5 + 6, d)$$

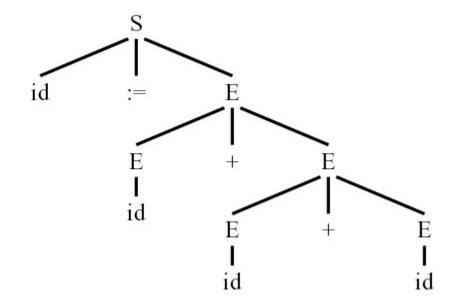


Gramáticas Ambíguas

 Podemos derivar uma sentença com duas parse trees diferentes?

- id := id+id+id





É Ambígua?

$$E \rightarrow id$$

 $E \rightarrow \text{num}$

$$E \rightarrow E * E$$

$$E \rightarrow E/E$$

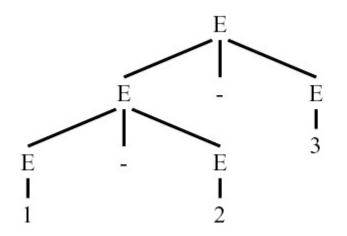
$$E \rightarrow E + E$$

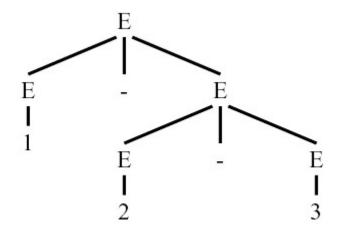
$$E \rightarrow E - E$$

$$E \rightarrow (E)$$

Construa Parse Trees para as seguintes expressões:

Exemplo: 1-2-3

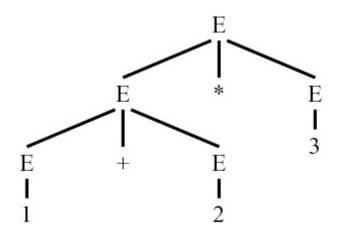


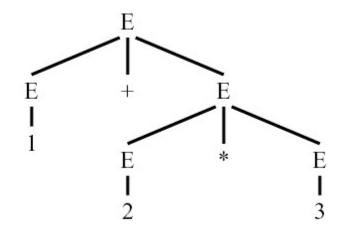


Ambígua!

$$(1-2)-3 = -4 e 1-(2-3) = 2$$

Exemplo: 1+2*3





Ambígua!

$$(1+2)*3 = 9 e 1+(2*3) = 7$$

Mas qual o problema com isto?



Gramáticas Ambiguas

- Os compiladores usam as parse trees para extrair o significado das expressões
- A ambiguidade se torna um problema
- Podemos, geralmente, mudar a gramática de maneira a retirar a ambigüidade

20

Gramáticas Ambíguas

Alterando o exemplo anterior:

- Queremos colocar uma precedência maior para * em relação a + e –
- Também queremos que cada operador seja associativo à esquerda:

(1-2)-3 e não 1-(2-3)

 Conseguimos isso introduzindo novos não-terminais

> MC910: Construção de Compiladores http://www.ic.unicamp.br/~guido



Gramática para Expressões

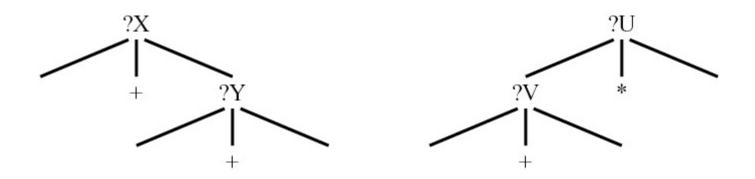
$$E \rightarrow E + T$$
 $T \rightarrow T^*F$ $F \rightarrow id$
 $E \rightarrow E - T$ $T \rightarrow T/F$ $F \rightarrow num$
 $E \rightarrow T$ $T \rightarrow F$ $F \rightarrow (E)$

Construa as derivações e Parse Trees para as seguintes expressões:

Gramática para Expressões

$$E \rightarrow E + T$$
 $T \rightarrow T^*F$ $F \rightarrow id$
 $E \rightarrow E - T$ $T \rightarrow T/F$ $F \rightarrow num$
 $E \rightarrow T$ $T \rightarrow F$ $F \rightarrow (E)$

Essa gramática pode gerar as árvores abaixo?







Gramáticas Ambíguas

- Geralmente podemos trasformar uma gramática para retirar a ambigüidade
- Algumas linguagens não possuem gramáticas não ambíguas
- Mas elas não seriam apropriadas como linguagens de programação





Fim de Arquivo

$$S \rightarrow E$$
\$

$$E \rightarrow E + T$$

$$E \rightarrow E - T$$

$$E \rightarrow T$$

$$T \rightarrow T * F$$

$$T \rightarrow T/F$$

$$T \rightarrow F$$

$$F \rightarrow id$$

$$F \rightarrow \text{num}$$

$$F \rightarrow (E)$$

Criar um novo não terminal como símbolo inicial





- Também chamados de recursivedescent
- É um algoritmo simples, capaz de fazer o parsing de algumas gramáticas
- Cada produção se torna uma cláusula em uma função recursiva
- Temos uma função para cada nãoterminal





 $S \rightarrow if E then S else S$

 $S \rightarrow begin S L$

 $S \rightarrow print E$

 $L \rightarrow end$

 $L \rightarrow ; SL$

 $E \rightarrow num = num$

Como seria um parser para essa gramática?





```
final int IF=1, THEN=2, ELSE=3, BEGIN=4, END=5, PRINT=6,
  SEMI=7, NUM=8, EQ=9;
int tok = getToken();
void advance() {tok=getToken();}
void eat(int t) {if (tok==t) advance(); else error();}
void S() {
  switch(tok) {
  case IF: eat(IF); E(); eat(THEN); S(); eat(ELSE); S();
  break;
  case BEGIN: eat(BEGIN); S(); L(); break;
  case PRINT: eat(PRINT); E(); break;
  default: error(); }}
 void L() {
  switch(tok) { case END: eat(END); break;
   case SEMI: eat(SEMI); S(); L(); break;
   default: error(); }}
 void E() { eat(NUM); eat(EQ); eat(NUM); }
```

$$S \rightarrow E$$
\$

$$E \rightarrow E + T$$

$$E \rightarrow E - T$$

$$E \rightarrow T$$

$$T \rightarrow T * F$$

$$T \rightarrow T/F$$

$$T \rightarrow F$$

$$F \rightarrow id$$

$$F \rightarrow \text{num}$$

$$F \rightarrow (E)$$

Vamos aplicar a mesma técnica para essa outra gramática ...





```
void S() { E(); eat(EOF); }
void E() {switch (tok) {
   case ?: E(); eat(PLUS); T(); break;
   case ?: E(); eat(MINUS); T(); break;
   case ?: T(); break;
   default: error(); }}
void T() {switch (tok) {
   case ?: T(); eat(TIMES); F(); break;
   case ?: T(); eat(DIV); F(); break;
   case ?: F(); break;
   default: error(); }}
```

Funciona ???

Como seria a execução para 1*2+3?

E para 1*2-3?

FIRST and FOLLOW sets

- Dada uma string γ de terminais e não terminais
 - FIRST(γ) é o conjunto de todos os terminais que podem iniciar uma string de terminais derivada de γ.
- Exemplo usando gramática anterior

$$-T \rightarrow T * F$$

$$- \gamma = T*F$$

• FIRST(γ) = {id ,num, (}

- Se uma gramática tem produções da forma:
 - X -> y1
 - X -> y2
 - Caso os conjuntos FIRST(γ1) e FIRST(γ2) tenham intersecção, então a gramática não pode ser analisada com um *predictive parser*
- Por que?
 - A função recursiva não vai saber que caso executar

Calculando FIRST

• Como seria para $\gamma = X Y Z$?

•
$$Z \rightarrow d$$

•
$$Z \rightarrow X Y Z$$

•
$$Y \rightarrow C$$

•
$$X \rightarrow Y$$

•
$$X \rightarrow a$$

Podemos simplesmente fazerFIRST(XYZ) = FIRST(X)?



Nullable

 Nullable(X) é verdadeiro se X pode derivar a string vazia

$$Z \rightarrow d$$

$$Z \rightarrow X Y Z$$

 $Y \rightarrow$

 $Y \rightarrow c$

 $X \rightarrow Y$

 $X \rightarrow a$

Nullable(Y)

Nullable(X)

Nullable(Z)







Nullable

 Nullable(X) é verdadeiro se X pode derivar a string vazia

$$Z \rightarrow d$$

$$Z \rightarrow X Y Z$$

$$Y \rightarrow$$

$$Y \rightarrow c$$

$$X \rightarrow Y$$

$$X \rightarrow a$$

$$Nullable(Y) = yes$$

$$Nullable(X) = yes$$

$$Nullable(Z) = no$$

FIRST

 FIRST(X) é o conjunto de terminais que podem iniciar strings derivadas de X

$$Z \rightarrow d$$
 FIRST(Y)
 $Z \rightarrow X Y Z$
 $Y \rightarrow$ FIRST(Z)
 $Y \rightarrow c$
 $X \rightarrow Y$
 $X \rightarrow a$





FIRST

 FIRST(X) é o conjunto de terminais que podem iniciar strings derivadas de X

$$Z \rightarrow d$$

$$Z \rightarrow X Y Z$$

$$Y \rightarrow$$

$$Y \rightarrow c$$

$$FIRST(Y) = \{c\}$$

$$FIRST(Z) = \{a,c,d\}$$

 $X \rightarrow Y$

 $X \rightarrow a$





FOLLOW

- FOLLOW(X) é o conjunto de terminais que podem imediatamente seguir X
 - t ∈ FOLLOW(X) se existe alguma derivação contendo Xt
 - Cuidado com derivações da forma X Y Z t, onde Y e Z podem ser vazios

$$Z \rightarrow d$$

FOLLOW(Y)

$$Z \rightarrow X Y Z$$

$$Y \rightarrow$$

FOLLOW(Z)

$$Y \rightarrow c$$

$$X \rightarrow Y$$

$$X \rightarrow a$$



FOLLOW

- FOLLOW(X) é o conjunto de terminais que podem imediatamente seguir X
 - t ∈ FOLLOW(X) se existe alguma derivação contendo Xt
 - Cuidado com derivações da forma X Y Z t, onde Y e Z podem ser vazios

$$Z \rightarrow d$$

$$Z \rightarrow X Y Z$$

$$Y \rightarrow$$

$$Y \rightarrow c$$

$$X \rightarrow Y$$

$$X \rightarrow a$$

$$FOLLOW(Y) = \{d,a,c\}$$

$$FOLLOW(Z) = \{ \}$$







Resumindo

- Nullable(X) é verdadeiro se X pode derivar a string vazia
- FIRST(y) é o conjunto de terminais que podem iniciar strings derivadas de y
- FOLLOW(X) é o conjunto de terminais que podem imediatamente seguir X
 - t ∈ FOLLOW(X) se existe alguma derivação contendo Xt
 - Cuidado com derivações da forma X Y Z t, onde Y e Z podem ser vazios

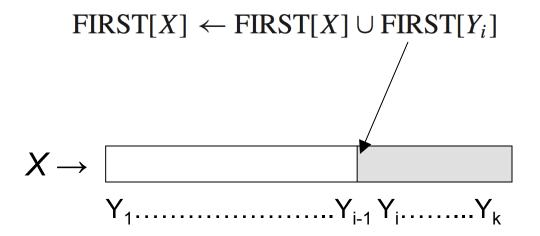


Definição FIRST, FOLLOW e nullable

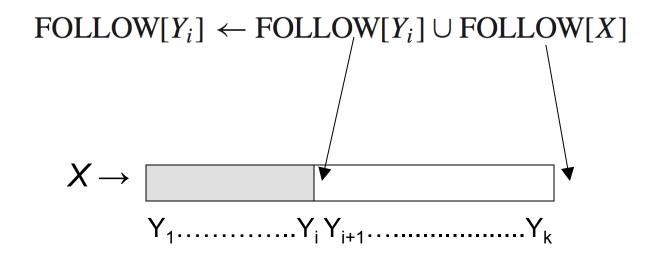
```
for each terminal symbol Z
    FIRST[Z] \leftarrow \{Z\}
repeat
    for each production X \to Y_1 Y_2 \cdots Y_k
        if Y_1 \dots Y_k are all nullable (or if k = 0)
          then nullable [X] \leftarrow true
        for each i from 1 to k, each j from i + 1 to k
            if Y_1 \cdots Y_{i-1} are all nullable (or if i = 1)
               then FIRST[X] \leftarrow FIRST[X] \cup FIRST[Y_i]
            if Y_{i+1} \cdots Y_k are all nullable (or if i = k)
               then FOLLOW[Y_i] \leftarrow FOLLOW[Y_i] \cup FOLLOW[X]
            if Y_{i+1} \cdots Y_{i-1} are all nullable (or if i+1=j)
               then FOLLOW[Y_i] \leftarrow FOLLOW[Y_i] \cup FIRST[Y_i]
until FIRST, FOLLOW, and nullable did not change in this iteration.
```



FIRST, FOLLOW, NULLABLE



FIRST, FOLLOW, NULLABLE









FIRST, FOLLOW, NULLABLE







Algoritmo FIRST, FOLLOW e nullable

- Algoritmo de iteração até um ponto fixo
- Os conjuntos poderiam ser computados de maneira separada
- Mesmo método usado para *E-closure*
- Aparece também no back-end, para dataflow analysis

 \boldsymbol{X}

•
$$Z \rightarrow d$$

•
$$Z \rightarrow X Y Z$$

•
$$Y \rightarrow C$$

•
$$X \rightarrow Y$$

•
$$X \rightarrow a$$

FIRST	FOLLOW
	FIRST

•
$$Z \rightarrow d$$

•
$$Z \rightarrow X Y Z$$

•
$$Y \rightarrow C$$

•
$$X \rightarrow Y$$

•
$$X \rightarrow a$$

	nullable	FIRST	FOLLOW
\boldsymbol{X}	no	a	c d
Y	yes	c	d
Z	no	d	

•
$$Z \rightarrow d$$

•
$$Z \rightarrow X Y Z$$

•
$$Y \rightarrow C$$

•
$$X \rightarrow Y$$

•
$$X \rightarrow a$$

	nullable	FIRST	FOLLOW
X	yes	a c	a c d
Y	yes	c	a c d
Z	no	a c d	

- Cada função relativa a um não-terminal precisa conter uma cláusula para cada produção
- Precisa saber escolher, baseado no próximo token, qual a produção apropriada
- Isto é feito através da predictive parsing table





	nullable	FIRST	FOLLOW	
\boldsymbol{X}	yes	a c	a c d	
Y	yes	c	a c d	Υ
Z	no	a c d		FIRST (XYZ)
		•	$Z \rightarrow d$	
		•	$Z \rightarrow X Y Z$	
		•	$Y \rightarrow$	FIRST (Y)
		•	$Y \rightarrow c$	*
		•	$X \rightarrow Y$	

• $X \rightarrow a$

Generalizando para strings

- FIRST($X\gamma$) = FIRST[X], if not nullable[X]
- FIRST(Xγ) = FIRST[X] U FIRST(γ),
 if nullable[X]
- string γ é nullable se cada símbolo em γ é nullable





- Dada uma produção X → γ
- Para cada t ∈ FIRST(γ)
 - Coloque a produção X → γ na linha X, coluna t.
- Se γ é nullable:
 - Coloque a produção na linha X, coluna t para cada t E
 FOLLOW[X].



•
$$Z \rightarrow d$$
 { } • $Y \rightarrow c$ { }
• $Z \rightarrow X Y Z$ { } • $X \rightarrow Y$ { }
• $Y \rightarrow$ { } • $X \rightarrow a$ { }

	nullable	FIRST	FOLLOW
\boldsymbol{X}	yes	ас	a c d
Y	yes	c	a c d
Z	no	a c d	

•
$$Z \rightarrow d$$

{d}

• $Y \rightarrow C$

{C}

•
$$Z \rightarrow X Y Z$$

{a,c,d}

X → Y

{a,c,d}

{a,c,d}

• $X \rightarrow a$

{a}

 a
 c
 d

 X
 Y

 Z

•
$$Z \rightarrow d$$

•
$$Y \rightarrow C$$

•
$$Z \rightarrow X Y Z$$

•
$$X \rightarrow a$$

Funciona ???

a

C

(

$$X \to a$$

$$X \to Y$$

$$X \to Y$$

Y

$$Y \rightarrow$$

$$Y \rightarrow$$

$$Y \rightarrow$$

$$Z \to XYZ$$

$$Z \rightarrow XYZ$$

 $Y \rightarrow c$

$$Z \rightarrow d$$

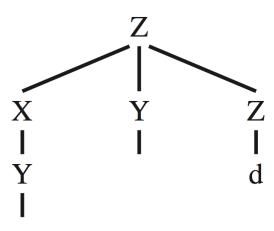
$$Z \to XYZ$$



Não!!

- A gramática é ambígua
- Note que algumas células da tabela do predictive parser têm mais de uma entrada!
- Isso sempre acontece com gramáticas ambíguas!

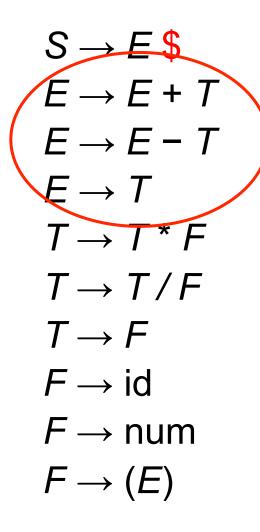
Z I d



- Linguagens cujas tabelas não possuam entradas duplicadas são denominadas de LL(1)
 - Left to right parsing, leftmost derivation, 1symbol lookahead
- A definição de conjuntos FIRST pode ser generalizada para os primeiros k tokens de uma string
 - Gera uma tabela onde as linhas são os não-terminais e as colunas são todas as seqüências possíveis de k terminais

- Isso é raramente feito devido ao tamanho explosivo das tabelas geradas
- Gramáticas analisáveis com tabelas LL(k) são chamadas LL(k)
- Nenhuma gramática ambígua é LL(k) para nenhum k!

MC910: Construção de Compiladores http://www.ic.unicamp.br/~guido



Consigo gerar um parser LL(1) para essa gramática?





$$S \rightarrow E$$
\$

$$E \rightarrow E - T$$

$$E \rightarrow E + T$$

$$E \rightarrow T$$

$$T \rightarrow T * F$$

$$T \rightarrow T/F$$

$$T \rightarrow F$$

$$F \rightarrow id$$

$$F \rightarrow \text{num}$$

$$F \rightarrow (E)$$

$$S \rightarrow E$$
\$

$$E \rightarrow E - T$$

$$E \rightarrow E + T$$

$$E \rightarrow T$$

$$T \rightarrow T * F$$

$$T \rightarrow T/F$$

$$T \rightarrow F$$

$$F \rightarrow id$$

$$F \rightarrow \text{num}$$

$$F \rightarrow (E)$$

O que fazer para resolver?

$$E \rightarrow T E'$$

$$E' \to + T E'$$

$$E' \rightarrow$$

Recursão à direita!

Generalizando:

- Tendo X → Xγ e X → α, onde α não começa com X
- Derivamos strings da forma αγ*
 - α seguido de zero ou mais γ.
- Podemos reescrever:

$$\begin{pmatrix} X \to X \gamma_1 \\ X \to X \gamma_2 \\ X \to \alpha_1 \\ X \to \alpha_2 \end{pmatrix} \Longrightarrow \begin{pmatrix} X \to \alpha_1 X' \\ X \to \alpha_2 X' \\ X' \to \gamma_1 X' \\ X' \to \gamma_2 X' \\ X' \to \gamma$$

Eliminando Recursão à Esquerda

•
$$S \rightarrow E$$
\$

•
$$T \rightarrow F T'$$

•
$$F \rightarrow id$$

•
$$E \rightarrow TE'$$

•
$$T' \rightarrow * F T'$$

•
$$E' \rightarrow + TE'$$
 • $T' \rightarrow /FT'$

•
$$T' \rightarrow / F T'$$

•
$$F \rightarrow (E)$$

•
$$E' \rightarrow TE'$$

	nullable	FIRST	FOLLOW
S	no	(id num	
\boldsymbol{E}	no	(id num) \$
E'	yes	+-) \$
T	no	(id num) + - \$
T'	yes	* /) + - \$
F	no	(id num)*/+-\$

Eliminando Recursão à Esquerda

•
$$S \rightarrow E$$
\$ • $T \rightarrow FT'$ • $F \rightarrow id$
• $E \rightarrow TE'$ • $T' \rightarrow FT'$ • $F \rightarrow num$
• $E' \rightarrow + TE'$ • $T' \rightarrow /FT'$ • $F \rightarrow (E)$

•
$$E' \rightarrow TE'$$
 • $T' \rightarrow$



Fatoração à Esquerda

 Um outro problema para predictive parsing ocorre em situações do tipo:

$$S \rightarrow \text{if } E \text{ then } S \text{ else } S$$

 $S \rightarrow \text{if } E \text{ then } S$

 Regras do mesmo não terminal começam com os mesmo símbolos

Fatoração à Esquerda

 Criar um novo não-terminal para os finais permitidos:

$$S \rightarrow \text{if } E \text{ then } S X$$

$$X \rightarrow X \rightarrow \text{else } S$$

 Gramática ainda é ambígua, mas conflito pode ser resolvido escolhendo sempre a segunda regra.



Recuperação de Erros

- Uma entrada em branco na tabela indica um caractere não esperado
- Parar o processo no primeiro erro encontrado não é desejável
- Duas alternativas:
 - Inserir símbolo:
 - Assume que encontrou o que esperava
 - Deletar símbolo(s):
 - Pula tokens até que um elemento do FOLLOW seja atingido.





Recuperação de Erros

```
void T() {
 switch (tok) {
   case ID:
   case NUM:
   case LPAREN: F(); Tprime(); break;
   default: print("expected id, num, or
 left-paren");
} }
```



Recuperação de Erros

```
int Tprime follow [] = {PLUS, RPAREN, EOF};
void Tprime() {
 switch (tok) {
   case PLUS: break;
   case TIMES: eat(TIMES); F(); Tprime(); break;
   case RPAREN: break;
   case EOF: break;
   default: print("expected +, *, right-paren, or
  end-of-file");
   skipto(Tprime follow);
 } }
```